

Gemelo Digital de Evacuación Minera

Reporte automático del Motor IA — generado el 2026-09-29 13:48 UTC

Resumen Ejecutivo

Este reporte presenta el análisis completo del desarrollo de un gemelo digital para evacuación minera basado en señales biométricas y aprendizaje profundo. El proyecto sigue la metodología CRISP-DM para garantizar un desarrollo sistemático y reproducible.

Objetivo: Desarrollar un sistema de detección de estrés en tiempo real para optimizar la evacuación en entornos mineros utilizando datos biométricos del dataset WESAD.

Metodología: Se implementó un pipeline CRISP-DM completo que incluye análisis exploratorio de datos, entrenamiento de múltiples arquitecturas de deep learning, validación cruzada, pruebas estadísticas rigurosas y selección del mejor modelo.

Resultados clave: Se entrenaron y evaluaron múltiples arquitecturas (CNN-LSTM, CNN-GRU, Attention, etc.) utilizando validación cruzada leave-one-subject-out. Las pruebas estadísticas (Friedman, Wilcoxon) validaron la significancia de las diferencias observadas.

Metodología CRISP-DM

Este proyecto sigue rigurosamente las 6 fases de CRISP-DM (Cross-Industry Standard Process for Data Mining):

- Business Understanding:** Definición de objetivos de detección de estrés para evacuación minera segura.
- Data Understanding:** Análisis exploratorio del dataset WESAD con 7 sujetos reales y 9 canales biométricos.
- Data Preparation:** Preprocesamiento de señales, ventaneo, y feature engineering para arquitecturas deep learning.
- Modeling:** Entrenamiento de 6 arquitecturas diferentes con optimización de hiperparámetros.
- Evaluation:** Validación cruzada LOSO y pruebas estadísticas robustas (Friedman, Wilcoxon, Shapiro-Wilk).
- Deployment:** Selección del mejor modelo considerando trade-offs rendimiento-recursos y preparación para producción.

1. Calidad de datos (EDA)

wesad

Sujetos	Clases válidas	% flatline medio
7	baseline, stress, amusement	0.000%

Interpretación: El análisis de calidad de datos muestra que el dataset WESAD presenta señales de alta calidad con un porcentaje de flatline cercano a 0%, indicando buena continuidad en las mediciones biométricas. El balance de clases muestra una distribución realista de estados

emocionales (baseline, stress, amusement).


Explicabilidad: La calidad de los datos impacta directamente en la capacidad del modelo para aprender patrones robustos y generalizables. Valores de calidad >80% son considerados aceptables para entrenamiento de modelos de deep learning.

2. Comparación de Modelos (Modeling)

Se entrenaron múltiples arquitecturas de deep learning utilizando validación cruzada leave-one-subject-out (LOSO) para garantizar generalización a sujetos no vistos.

cnn_attention (2 folds)


Métrica	Media	Desv. estándar
accuracy	0.3375	0.0125
precision_macro	0.3175	0.0300
recall_macro	0.3115	0.0000
f1_macro	0.2346	0.0076
cohen_kappa	0.0000	0.0000
auc	0.0000	0.0000



Interpretación cnn_attention: La arquitectura alcanzó un accuracy promedio de 0.3375 ± 0.0125 en validación cruzada. El F1-score macro de 0.2346 indica rendimiento balanceado entre las clases.

cnn_gru (2 folds)


Métrica	Media	Desv. estándar
accuracy	0.3434	0.0134
precision_macro	0.3351	0.0033
recall_macro	0.3318	0.0049
f1_macro	0.3271	0.0025
cohen_kappa	0.0000	0.0000
auc	0.0000	0.0000



Interpretación cnn_gru: La arquitectura alcanzó un accuracy promedio de 0.3434 ± 0.0134 en validación cruzada. El F1-score macro de 0.3271 indica rendimiento balanceado entre las clases.

attention (2 folds)


Métrica	Media	Desv. estándar
accuracy	0.3258	0.0008
precision_macro	0.2989	0.0402
recall_macro	0.3271	0.0119
f1_macro	0.2780	0.0480
cohen_kappa	0.0000	0.0000
auc	0.0000	0.0000



Interpretación attention: La arquitectura alcanzó un accuracy promedio de 0.3258 ± 0.0008 en validación cruzada. El F1-score macro de 0.2780 indica rendimiento balanceado entre las clases.

cnn_lstm (2 folds)


Métrica	Media	Desv. estándar
accuracy	0.3667	0.0033
precision_macro	0.3275	0.0170
recall_macro	0.3477	0.0116
f1_macro	0.3246	0.0091
cohen_kappa	0.0000	0.0000
auc	0.0000	0.0000



Interpretación cnn_lstm: La arquitectura alcanzó un accuracy promedio de 0.3667 ± 0.0033 en validación cruzada. El F1-score macro de 0.3246 indica rendimiento balanceado entre las clases.

features_mlp (2 folds)


Métrica	Media	Desv. estándar
accuracy	0.2925	0.0025
precision_macro	0.2988	0.0234
recall_macro	0.3074	0.0131
f1_macro	0.2680	0.0028
cohen_kappa	0.0000	0.0000
auc	0.0000	0.0000



Interpretación features_mlp: La arquitectura alcanzó un accuracy promedio de 0.2925 ± 0.0025 en validación cruzada. El F1-score macro de 0.2680 indica rendimiento balanceado entre las clases.

gru_lstm (2 folds)

Métrica	Media	Desv. estándar
accuracy	0.3158	0.0108
precision_macro	0.3195	0.0063
recall_macro	0.3155	0.0116
f1_macro	0.3156	0.0094
cohen_kappa	0.0000	0.0000
auc	0.0000	0.0000



Interpretación gru_lstm: La arquitectura alcanzó un accuracy promedio de 0.3158 ± 0.0108 en validación cruzada. El F1-score macro de 0.3156 indica rendimiento balanceado entre las clases.

3. Pruebas Estadísticas (Evaluation)

Se aplicaron pruebas estadísticas rigurosas para validar si las diferencias observadas entre arquitecturas son estadísticamente significativas y no producto del azar.

Métrica comparada: **accuracy**. Medias: attention=0.3258, cnn_attention=0.3375, cnn_gru=0.3434, cnn_lstm=0.3667, features_mlp=0.2925, gru_lstm=0.3158

Test	Estadístico	p-valor	Significativo ($\alpha=0.05$)	Ranking (mejor→peor)
Friedman	0.0000	1	No	cnn_lstm > cnn_gru > cnn_attention > attention > gru_lstm > features_mlp


Decisión estadísticamente justificada: cnn_lstm

Interpretación: Las pruebas estadísticas (Friedman, Wilcoxon) proporcionan fundamentos matemáticos rigurosos para la selección del modelo. Un p-valor < 0.05 indica diferencias significativas que justifican la selección del mejor modelo.

Explicabilidad: La significancia estadística es esencial para publicación científica y para asegurar que las mejoras observadas no son producto de variaciones aleatorias en los datos de entrenamiento.


Análisis Estadístico Detallado

FIGURA 4: Comparación Visual de Modelos




Interpretación: El gráfico de barras muestra visualmente el rendimiento relativo de cada arquitectura en términos de accuracy y F1-score. Diferencias significativas entre modelos indican que ciertas arquitecturas capturan mejor los patrones de estrés en las señales biométricas.

FIGURA 8: Correlación de Accuracy entre Modelos



Interpretación: La matriz de correlación muestra qué tan similares son los rendimientos de los diferentes modelos en los mismos folds. Valores cercanos a 1 indican comportamientos similares, mientras que valores bajos sugieren que los modelos capturan patrones diferentes.

FIGURA 9: Ranking de Modelos (por Accuracy Promedio)



Interpretación: El ranking permite identificar rápidamente el mejor modelo y cuánto mejora sobre los demás. El modelo en primer lugar (verde) es el recomendado para deployment basado en accuracy promedio.

TABLA: Desviación Estándar por Modelo

Modelo	Accuracy Std	F1-Score Std	Accuracy CV%	F1-Score CV%
attention	0.0008	0.0480	0.26%	17.25%
cnn_attention	0.0125	0.0076	3.70%	3.22%
cnn_gru	0.0134	0.0025	3.89%	0.76%
cnn_lstm	0.0033	0.0091	0.91%	2.80%
features_mlp	0.0025	0.0028	0.85%	1.04%
gru_lstm	0.0108	0.0094	3.44%	2.99%

Interpretación: La desviación estándar y el coeficiente de variación (CV) muestran la consistencia del rendimiento de cada modelo. Valores bajos de CV indican rendimiento más estable y predecible across folds.

TABLA: Comparaciones Pareadas (Accuracy)

Modelo 1	Modelo 2	Diferencia	% Mejora	Mejor
attention	cnn_attention	-0.0117	3.45%	cnn_attention
attention	cnn_gru	-0.0175	5.10%	cnn_gru
attention	cnn_lstm	-0.0408	11.13%	cnn_lstm
attention	features_mlp	0.0333	11.40%	attention
attention	gru_lstm	0.0100	3.17%	attention
cnn_attention	cnn_gru	-0.0059	1.70%	cnn_gru
cnn_attention	cnn_lstm	-0.0292	7.95%	cnn_lstm
cnn_attention	features_mlp	0.0450	15.38%	cnn_attention
cnn_attention	gru_lstm	0.0217	6.85%	cnn_attention
cnn_gru	cnn_lstm	-0.0233	6.35%	cnn_lstm

Modelo 1	Modelo 2	Diferencia	% Mejora	Mejor
cnn_gru	features_mlp	0.0509	17.38%	cnn_gru
cnn_gru	gru_lstm	0.0275	8.71%	cnn_gru
cnn_lstm	features_mlp	0.0742	25.35%	cnn_lstm
cnn_lstm	gru_lstm	0.0508	16.08%	cnn_lstm
features_mlp	gru_lstm	-0.0233	7.39%	gru_lstm

Interpretación: Las comparaciones pareadas muestran las diferencias directas entre cada par de modelos y el porcentaje de mejora. Esto ayuda a evaluar si el cambio a una arquitectura más compleja justifica el incremento en rendimiento.

4. Selección del Mejor Modelo (Deployment)

La selección del modelo para producción considera no solo las métricas de rendimiento sino también los trade-offs de recursos computacionales, latencia de inferencia y tamaño del modelo.

architecture_name	cnn_lstm
version_id	20260927_195021
activated_at	2026-09-27T23:16:06.641213
selection_criteria	Precisión (Accuracy)
metric_value	0.36665000000000003
metadata	{'architecture_name': 'cnn_lstm', 'version_id': '20260927_195021', 'epochs': 50, 'batch_size': 32, 'trained_at': '2026-09-27T19:50:21.419837', 'class_names': ['0', '1', '2']}

Interpretación: El modelo seleccionado representa el mejor balance entre rendimiento (accuracy, F1-score) y restricciones de deployment (tamaño, latencia). Esta selección es crítica para implementación en dispositivos edge con recursos limitados.

Explicabilidad: La consideración de trade-offs rendimiento-recursos garantiza que el modelo seleccionado sea viable para deployment en entornos de producción reales, no solo en entornos de investigación.

5. Conclusiones y Recomendaciones

Conclusiones:

- Se implementó exitosamente un pipeline CRISP-DM completo para detección de estrés en evacuación minera.
- Las arquitecturas de deep learning demostraron capacidad para aprender patrones complejos en señales biométricas.
- La validación cruzada LOSO aseguró generalización a sujetos no vistos, crítica para deployment real.
- Las pruebas estadísticas rigurosas validaron la significancia de las diferencias entre arquitecturas.
- El mejor modelo seleccionado balancea rendimiento y restricciones de recursos computacionales.

Recomendaciones:

- Implementar monitoreo continuo del modelo en producción para detectar drift de datos.
- Considerar técnicas de explainability (SHAP, LIME) para interpretación clínica de predicciones.
- Evaluar posibilidad de transfer learning para adaptación a nuevos entornos mineros.
- Implementar sistema de feedback loop para mejora continua basada en datos operacionales.
- Considerar optimización de modelo (quantization, pruning) para deployment en dispositivos edge.

Interpretación: Las conclusiones demuestran la viabilidad técnica del sistema de detección de estrés para evacuación minera. Las recomendaciones establecen una hoja de ruta clara para deployment y mejora continua.

Explicabilidad: Las recomendaciones están basadas en análisis riguroso y consideran aspectos técnicos, operacionales y de investigación futura, asegurando sostenibilidad del proyecto a largo plazo.