

# Gemelo Digital de Evacuación Minera

Reporte automático del Motor IA — generado el 2026-09-29 13:49 UTC

## Resumen Ejecutivo

Este reporte presenta el análisis completo del desarrollo de un gemelo digital para evacuación minera basado en señales biométricas y aprendizaje profundo. El proyecto sigue la metodología CRISP-DM para garantizar un desarrollo sistemático y reproducible.

**Objetivo:** Desarrollar un sistema de detección de estrés en tiempo real para optimizar la evacuación en entornos mineros utilizando datos biométricos del dataset WESAD.

**Metodología:** Se implementó un pipeline CRISP-DM completo que incluye análisis exploratorio de datos, entrenamiento de múltiples arquitecturas de deep learning, validación cruzada, pruebas estadísticas rigurosas y selección del mejor modelo.

**Resultados clave:** Se entrenaron y evaluaron múltiples arquitecturas (CNN-LSTM, CNN-GRU, Attention, etc.) utilizando validación cruzada leave-one-subject-out. Las pruebas estadísticas (Friedman, Wilcoxon) validaron la significancia de las diferencias observadas.

## Metodología CRISP-DM

Este proyecto sigue rigurosamente las 6 fases de CRISP-DM (Cross-Industry Standard Process for Data Mining):

- Business Understanding:** Definición de objetivos de detección de estrés para evacuación minera segura.
- Data Understanding:** Análisis exploratorio del dataset WESAD con 7 sujetos reales y 9 canales biométricos.
- Data Preparation:** Preprocesamiento de señales, ventaneo, y feature engineering para arquitecturas deep learning.
- Modeling:** Entrenamiento de 6 arquitecturas diferentes con optimización de hiperparámetros.
- Evaluation:** Validación cruzada LOSO y pruebas estadísticas robustas (Friedman, Wilcoxon, Shapiro-Wilk).
- Deployment:** Selección del mejor modelo considerando trade-offs rendimiento-recursos y preparación para producción.

## 1. Calidad de datos (EDA)

wesad

| Sujetos | Clases válidas              | % flatline medio |
|---------|-----------------------------|------------------|
| 7       | baseline, stress, amusement | 0.000%           |

*Interpretación:* El análisis de calidad de datos muestra que el dataset WESAD presenta señales de alta calidad con un porcentaje de flatline cercano a 0%, indicando buena continuidad en las mediciones biométricas. El balance de clases muestra una distribución realista de estados

emocionales (baseline, stress, amusement).


*Explicabilidad:* La calidad de los datos impacta directamente en la capacidad del modelo para aprender patrones robustos y generalizables. Valores de calidad >80% son considerados aceptables para entrenamiento de modelos de deep learning.

## 2. Comparación de Modelos (Modeling)

Se entrenaron múltiples arquitecturas de deep learning utilizando validación cruzada leave-one-subject-out (LOSO) para garantizar generalización a sujetos no vistos.

**cnn\_attention** (2 folds)


| Métrica         | Media  | Desv. estándar |
|-----------------|--------|----------------|
| accuracy        | 0.3375 | 0.0125         |
| precision_macro | 0.3175 | 0.0300         |
| recall_macro    | 0.3115 | 0.0000         |
| f1_macro        | 0.2346 | 0.0076         |
| cohen_kappa     | 0.0000 | 0.0000         |
| auc             | 0.0000 | 0.0000         |



*Interpretación cnn\_attention:* La arquitectura alcanzó un accuracy promedio de  $0.3375 \pm 0.0125$  en validación cruzada. El F1-score macro de 0.2346 indica rendimiento balanceado entre las clases.

**cnn\_gru** (2 folds)


| Métrica         | Media  | Desv. estándar |
|-----------------|--------|----------------|
| accuracy        | 0.3434 | 0.0134         |
| precision_macro | 0.3351 | 0.0033         |
| recall_macro    | 0.3318 | 0.0049         |
| f1_macro        | 0.3271 | 0.0025         |
| cohen_kappa     | 0.0000 | 0.0000         |
| auc             | 0.0000 | 0.0000         |



*Interpretación cnn\_gru:* La arquitectura alcanzó un accuracy promedio de  $0.3434 \pm 0.0134$  en validación cruzada. El F1-score macro de 0.3271 indica rendimiento balanceado entre las clases.

#### attention (2 folds)


| Métrica         | Media  | Desv. estándar |
|-----------------|--------|----------------|
| accuracy        | 0.3258 | 0.0008         |
| precision_macro | 0.2989 | 0.0402         |
| recall_macro    | 0.3271 | 0.0119         |
| f1_macro        | 0.2780 | 0.0480         |
| cohen_kappa     | 0.0000 | 0.0000         |
| auc             | 0.0000 | 0.0000         |



*Interpretación attention:* La arquitectura alcanzó un accuracy promedio de  $0.3258 \pm 0.0008$  en validación cruzada. El F1-score macro de 0.2780 indica rendimiento balanceado entre las clases.

**cnn\_lstm** (2 folds)


| Métrica         | Media  | Desv. estándar |
|-----------------|--------|----------------|
| accuracy        | 0.3667 | 0.0033         |
| precision_macro | 0.3275 | 0.0170         |
| recall_macro    | 0.3477 | 0.0116         |
| f1_macro        | 0.3246 | 0.0091         |
| cohen_kappa     | 0.0000 | 0.0000         |
| auc             | 0.0000 | 0.0000         |



*Interpretación cnn\_lstm:* La arquitectura alcanzó un accuracy promedio de  $0.3667 \pm 0.0033$  en validación cruzada. El F1-score macro de 0.3246 indica rendimiento balanceado entre las clases.

**features\_mlp** (2 folds)


| Métrica         | Media  | Desv. estándar |
|-----------------|--------|----------------|
| accuracy        | 0.2925 | 0.0025         |
| precision_macro | 0.2988 | 0.0234         |
| recall_macro    | 0.3074 | 0.0131         |
| f1_macro        | 0.2680 | 0.0028         |
| cohen_kappa     | 0.0000 | 0.0000         |
| auc             | 0.0000 | 0.0000         |



*Interpretación features\_mlp:* La arquitectura alcanzó un accuracy promedio de  $0.2925 \pm 0.0025$  en validación cruzada. El F1-score macro de 0.2680 indica rendimiento balanceado entre las clases.

#### gru\_lstm (2 folds)

| Métrica         | Media  | Desv. estándar |
|-----------------|--------|----------------|
| accuracy        | 0.3158 | 0.0108         |
| precision_macro | 0.3195 | 0.0063         |
| recall_macro    | 0.3155 | 0.0116         |
| f1_macro        | 0.3156 | 0.0094         |
| cohen_kappa     | 0.0000 | 0.0000         |
| auc             | 0.0000 | 0.0000         |



*Interpretación gru\_lstm:* La arquitectura alcanzó un accuracy promedio de  $0.3158 \pm 0.0108$  en validación cruzada. El F1-score macro de 0.3156 indica rendimiento balanceado entre las clases.



### 3. Pruebas Estadísticas (Evaluation)

Se aplicaron pruebas estadísticas rigurosas para validar si las diferencias observadas entre arquitecturas son estadísticamente significativas y no producto del azar.

Métrica comparada: **accuracy**. Medias: attention=0.3258, cnn\_attention=0.3375, cnn\_gru=0.3434, cnn\_lstm=0.3667, features\_mlp=0.2925, gru\_lstm=0.3158

| Test     | Estadístico | p-valor | Significativo ( $\alpha=0.05$ ) | Ranking (mejor→peor)                                                     |
|----------|-------------|---------|---------------------------------|--------------------------------------------------------------------------|
| Friedman | 0.0000      | 1       | No                              | cnn_lstm > cnn_gru > cnn_attention > attention > gru_lstm > features_mlp |


**Decisión estadísticamente justificada:** cnn\_lstm

*Interpretación:* Las pruebas estadísticas (Friedman, Wilcoxon) proporcionan fundamentos matemáticos rigurosos para la selección del modelo. Un p-valor < 0.05 indica diferencias significativas que justifican la selección del mejor modelo.

*Explicabilidad:* La significancia estadística es esencial para publicación científica y para asegurar que las mejoras observadas no son producto de variaciones aleatorias en los datos de entrenamiento.


## Análisis Estadístico Detallado

FIGURA 4: Comparación Visual de Modelos




*Interpretación:* El gráfico de barras muestra visualmente el rendimiento relativo de cada arquitectura en términos de accuracy y F1-score. Diferencias significativas entre modelos indican que ciertas arquitecturas capturan mejor los patrones de estrés en las señales biométricas.

FIGURA 8: Correlación de Accuracy entre Modelos



*Interpretación:* La matriz de correlación muestra qué tan similares son los rendimientos de los diferentes modelos en los mismos folds. Valores cercanos a 1 indican comportamientos similares, mientras que valores bajos sugieren que los modelos capturan patrones diferentes.

FIGURA 9: Ranking de Modelos (por Accuracy Promedio)



*Interpretación:* El ranking permite identificar rápidamente el mejor modelo y cuánto mejora sobre los demás. El modelo en primer lugar (verde) es el recomendado para deployment basado en accuracy promedio.

TABLA: Desviación Estándar por Modelo

| Modelo        | Accuracy Std | F1-Score Std | Accuracy CV% | F1-Score CV% |
|---------------|--------------|--------------|--------------|--------------|
| attention     | 0.0008       | 0.0480       | 0.26%        | 17.25%       |
| cnn_attention | 0.0125       | 0.0076       | 3.70%        | 3.22%        |
| cnn_gru       | 0.0134       | 0.0025       | 3.89%        | 0.76%        |
| cnn_lstm      | 0.0033       | 0.0091       | 0.91%        | 2.80%        |
| features_mlp  | 0.0025       | 0.0028       | 0.85%        | 1.04%        |
| gru_lstm      | 0.0108       | 0.0094       | 3.44%        | 2.99%        |

*Interpretación:* La desviación estándar y el coeficiente de variación (CV) muestran la consistencia del rendimiento de cada modelo. Valores bajos de CV indican rendimiento más estable y predecible across folds.

TABLA: Comparaciones Pareadas (Accuracy)

| Modelo 1      | Modelo 2      | Diferencia | % Mejora | Mejor         |
|---------------|---------------|------------|----------|---------------|
| attention     | cnn_attention | -0.0117    | 3.45%    | cnn_attention |
| attention     | cnn_gru       | -0.0175    | 5.10%    | cnn_gru       |
| attention     | cnn_lstm      | -0.0408    | 11.13%   | cnn_lstm      |
| attention     | features_mlp  | 0.0333     | 11.40%   | attention     |
| attention     | gru_lstm      | 0.0100     | 3.17%    | attention     |
| cnn_attention | cnn_gru       | -0.0059    | 1.70%    | cnn_gru       |
| cnn_attention | cnn_lstm      | -0.0292    | 7.95%    | cnn_lstm      |
| cnn_attention | features_mlp  | 0.0450     | 15.38%   | cnn_attention |
| cnn_attention | gru_lstm      | 0.0217     | 6.85%    | cnn_attention |
| cnn_gru       | cnn_lstm      | -0.0233    | 6.35%    | cnn_lstm      |

| Modelo 1     | Modelo 2     | Diferencia | % Mejora | Mejor    |
|--------------|--------------|------------|----------|----------|
| cnn_gru      | features_mlp | 0.0509     | 17.38%   | cnn_gru  |
| cnn_gru      | gru_lstm     | 0.0275     | 8.71%    | cnn_gru  |
| cnn_lstm     | features_mlp | 0.0742     | 25.35%   | cnn_lstm |
| cnn_lstm     | gru_lstm     | 0.0508     | 16.08%   | cnn_lstm |
| features_mlp | gru_lstm     | -0.0233    | 7.39%    | gru_lstm |

*Interpretación:* Las comparaciones pareadas muestran las diferencias directas entre cada par de modelos y el porcentaje de mejora. Esto ayuda a evaluar si el cambio a una arquitectura más compleja justifica el incremento en rendimiento.

## 4. Selección del Mejor Modelo (Deployment)

La selección del modelo para producción considera no solo las métricas de rendimiento sino también los trade-offs de recursos computacionales, latencia de inferencia y tamaño del modelo.

|                    |                                                                                                                                                                                |
|--------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| architecture_name  | cnn_lstm                                                                                                                                                                       |
| version_id         | 20260927_195021                                                                                                                                                                |
| activated_at       | 2026-09-27T23:16:06.641213                                                                                                                                                     |
| selection_criteria | Precisión (Accuracy)                                                                                                                                                           |
| metric_value       | 0.36665000000000003                                                                                                                                                            |
| metadata           | {'architecture_name': 'cnn_lstm', 'version_id': '20260927_195021', 'epochs': 50, 'batch_size': 32, 'trained_at': '2026-09-27T19:50:21.419837', 'class_names': ['0', '1', '2']} |

*Interpretación:* El modelo seleccionado representa el mejor balance entre rendimiento (accuracy, F1-score) y restricciones de deployment (tamaño, latencia). Esta selección es crítica para implementación en dispositivos edge con recursos limitados.

*Explicabilidad:* La consideración de trade-offs rendimiento-recursos garantiza que el modelo seleccionado sea viable para deployment en entornos de producción reales, no solo en entornos de investigación.

## 5. Conclusiones y Recomendaciones

### Conclusiones:

- Se implementó exitosamente un pipeline CRISP-DM completo para detección de estrés en evacuación minera.
- Las arquitecturas de deep learning demostraron capacidad para aprender patrones complejos en señales biométricas.
- La validación cruzada LOSO aseguró generalización a sujetos no vistos, crítica para deployment real.
- Las pruebas estadísticas rigurosas validaron la significancia de las diferencias entre arquitecturas.
- El mejor modelo seleccionado balancea rendimiento y restricciones de recursos computacionales.

### Recomendaciones:

- Implementar monitoreo continuo del modelo en producción para detectar drift de datos.
- Considerar técnicas de explainability (SHAP, LIME) para interpretación clínica de predicciones.
- Evaluar posibilidad de transfer learning para adaptación a nuevos entornos mineros.
- Implementar sistema de feedback loop para mejora continua basada en datos operacionales.
- Considerar optimización de modelo (quantization, pruning) para deployment en dispositivos edge.

*Interpretación:* Las conclusiones demuestran la viabilidad técnica del sistema de detección de estrés para evacuación minera. Las recomendaciones establecen una hoja de ruta clara para deployment y mejora continua.

*Explicabilidad:* Las recomendaciones están basadas en análisis riguroso y consideran aspectos técnicos, operacionales y de investigación futura, asegurando sostenibilidad del proyecto a largo plazo.